



# Învățarea din observații - Amintire

## Problema Estimării (Antrenării) Modelului

Dându-se un set de secvențe observate  $\mathcal{O} = [O_1 O_2 \dots O_L]$ , cum ajustăm **parametrii**  $\lambda = (A, B, \Pi)$  ai unui MMA care încearcă să explice cel mai bine acele observații?

Secvențele de observații folosite pentru ajustarea parametrilor modelului se numesc secvențe **de antrenare**.

Problema antrenării este esențială - ea permite crearea celor mai bune modele pentru fenomene reale.

# Învătarea din observații - Abordare





# Învățarea din observații - Abordare

## Problemă

Nu se cunoaște o metodă analitică de căutare a parametrilor modelului care *maximizează* probabilitatea secvențelor observate.



# Învățarea din observații - Abordare

## Problemă

Nu se cunoaște o metodă analitică de căutare a parametrilor modelului care *maximizează* probabilitatea secvențelor observate.

## Soluție

Putem totuși găsi  $\lambda = (A, B, \Pi)$ , astfel încât  $\max_{\lambda} P(O|\lambda)$  corespunde unui **maxim local**, utilizând o **procedură iterativă** precum *algoritmul Baum-Welch*. Această metodă este o instanță a *algoritmului EM (Expectation Maximization)* [DLR77] pentru cazul MMA.



# Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

1. Avem MMA  $\lambda = (A, B, \Pi)$  și o secvență observată  $O$



# Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ❶ Avem MMA  $\lambda = (A, B, \Pi)$  și o secvență observată  $O$
- ❷ Calculăm folosindu-ne de parametrii  $\alpha_t(i)$  și  $\beta_t(i)$ 
  - nr. estimat de tranziții din  $S_i$ , pentru fiecare  $1 \leq i \leq N$
  - nr. estimat de tranziții din  $S_i$  la  $S_j$ , pentru fiecare  $1 \leq i \leq N, 1 \leq j \leq N$
  - nr. estimat de vizite în  $S_j$  observând simbolul  $v_k$ , pentru fiecare  $1 \leq j \leq N, 1 \leq k \leq M$



# Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ❶ Avem MMA  $\lambda = (A, B, \Pi)$  și o secvență observată  $O$
- ❷ Calculăm folosindu-ne de parametrii  $\alpha_t(i)$  și  $\beta_t(i)$ 
  - nr. estimat de tranziții din  $S_i$ , pentru fiecare  $1 \leq i \leq N$
  - nr. estimat de tranziții din  $S_i$  la  $S_j$ , pentru fiecare  $1 \leq i \leq N, 1 \leq j \leq N$
  - nr. estimat de vizite în  $S_j$  observând simbolul  $v_k$ , pentru fiecare  $1 \leq j \leq N, 1 \leq k \leq M$
- ❸ Dacă modelul este corect ne așteptăm ca
  - (a)  $\Pi_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t=1) = \bar{\Pi}_i$
  - (b)  $a_{i,j} = \frac{\text{nr. estimat de tranziții din } S_i \text{ la } S_j}{\text{nr. estimat de tranziții din } S_i} = \bar{a}_{i,j}$
  - (c)  $b_{j,k} = \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} = \bar{b}_{j,k}$



# Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ❶ Avem MMA  $\lambda = (A, B, \Pi)$  și o secvență observată  $O$
- ❷ Calculăm folosindu-ne de parametrii  $\alpha_t(i)$  și  $\beta_t(i)$ 
  - nr. estimat de tranziții din  $S_i$ , pentru fiecare  $1 \leq i \leq N$
  - nr. estimat de tranziții din  $S_i$  la  $S_j$ , pentru fiecare  $1 \leq i \leq N, 1 \leq j \leq N$
  - nr. estimat de vizite în  $S_j$  observând simbolul  $v_k$ , pentru fiecare  $1 \leq j \leq N, 1 \leq k \leq M$
- ❸ Dacă modelul este corect ne așteptăm ca
  - (a)  $\Pi_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t=1) = \bar{\Pi}_i$
  - (b)  $a_{i,j} = \frac{\text{nr. estimat de tranziții din } S_i \text{ la } S_j}{\text{nr. estimat de tranziții din } S_i} = \bar{a}_{i,j}$
  - (c)  $b_{j,k} = \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} = \bar{b}_{j,k}$
- ❹ Vedem că raporturile calculate din presupunerea noastră explică mai bine observația decât parametrii anteriori, i.e.  $P(O|\bar{\lambda}) > P(O|\lambda)$





# Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ❶ Avem MMA  $\lambda = (A, B, \Pi)$  și o secvență observată  $O$
- ❷ Calculăm folosindu-ne de parametrii  $\alpha_t(i)$  și  $\beta_t(i)$ 
  - nr. estimat de tranziții din  $S_i$ , pentru fiecare  $1 \leq i \leq N$
  - nr. estimat de tranziții din  $S_i$  la  $S_j$ , pentru fiecare  $1 \leq i \leq N, 1 \leq j \leq N$
  - nr. estimat de vizite în  $S_j$  observând simbolul  $v_k$ , pentru fiecare  $1 \leq j \leq N, 1 \leq k \leq M$
- ❸ Dacă modelul este corect ne așteptăm ca
  - (a)  $\Pi_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t=1) = \bar{\Pi}_i$
  - (b)  $a_{i,j} = \frac{\text{nr. estimat de tranziții din } S_i \text{ la } S_j}{\text{nr. estimat de tranziții din } S_i} = \bar{a}_{i,j}$
  - (c)  $b_{j,k} = \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} = \bar{b}_{j,k}$
- ❹ Vedem că raporturile calculate din presupunerea noastră explică mai bine observația decât parametrii anteriori, i.e.  $P(O|\bar{\lambda}) > P(O|\lambda)$
- ❺ Atunci repetăm procesul până ce suntem mulțumiți (convergență):  

$$P(O|\bar{\lambda}) - P(O|\lambda) \leq \epsilon$$

# Algoritmul Baum-Welch (II)





## Algoritmul Baum-Welch (II)

Definim întâi niște variabile auxiliare:

$$\xi_{t,i,j} = \xi_t(i,j) = P(q_t = s_i, q_{t+1} = s_j | O, \lambda)$$

Probabilitatea de a fi în starea  $s_i$  la momentul  $t$  și în starea  $s_j$  la momentul  $t + 1$ , condiționat de parametrii modelului curent și secvența observată.



## Algoritmul Baum-Welch (II)

Definim întâi niște variabile auxiliare:

$$\xi_{t,i,j} = \xi_t(i,j) = P(q_t = s_i, q_{t+1} = s_j | O, \lambda)$$

Probabilitatea de a fi în starea  $s_i$  la momentul  $t$  și în starea  $s_j$  la momentul  $t + 1$ , condiționat de parametrii modelului curent și secvența observată.

$$\gamma_{t,i} = \gamma_t(i) = P(q_t = s_i | O, \lambda)$$

Probabilitatea de a fi în starea  $s_i$  la momentul  $t$ , condiționat de parametrii modelului curent și secvența observată.



## Algoritmul Baum-Welch (II)

Definim întâi niște variabile auxiliare:

$$\xi_{t,i,j} = \xi_t(i,j) = P(q_t = s_i, q_{t+1} = s_j | O, \lambda)$$

Probabilitatea de a fi în starea  $s_i$  la momentul  $t$  și în starea  $s_j$  la momentul  $t + 1$ , condiționat de parametrii modelului curent și secvența observată.

$$\gamma_{t,i} = \gamma_t(i) = P(q_t = s_i | O, \lambda)$$


Probabilitatea de a fi în starea  $s_i$  la momentul  $t$ , condiționat de parametrii modelului curent și secvența observată.

Din definiții rezultă că:

$$\gamma_t(i) = \sum_{j=1}^N \xi_t(i,j)$$



# Algoritmul Baum-Welch (III)



Secvența de operații necesară pentru calculul evenimentului mixt ca sistemul se află în starea  $S_i$  la momentul  $t$  și în starea  $S_j$  la momentul  $t + 1$

$$\alpha_{t,i} = P(o_1, o_2, \dots, o_t, q_t = S_i | \lambda) \quad (36)$$

$$\beta_{t,i} = P(o_{t+1} o_{t+2} \dots o_T | q_t = S_i, \lambda) \quad (37)$$

$$\begin{aligned} \xi_t(i, j) &= \frac{\alpha_{t,i} \cdot a_{i,j} \cdot b_j(o_{t+1}) \cdot \beta_{t+1,j}}{P(O | \lambda)} \\ &= \frac{\alpha_{t,i} \cdot a_{i,j} \cdot b_j(o_{t+1}) \cdot \beta_{t+1,j}}{\sum_{k=1}^N \sum_{l=1}^N \alpha_{t,k} \cdot a_{k,l} \cdot b_l(o_{t+1}) \cdot \beta_{t+1,l}} \quad (38) \end{aligned}$$



## Algoritmul Baum-Welch (IV)

Cum ne ajută aceste variabile auxiliare?

$$\sum_{t=1}^{T-1} \gamma_t(i) = \text{numărul estimat de tranziții din } S_i$$

$$\sum_{t=1}^{T-1} \xi_t(i, j) = \text{numărul estimat de tranziții din } S_i \text{ la } S_j$$



# Algoritmul Baum-Welch (V)

$$\bar{\pi}_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t = 1) = \gamma_1(i) \quad (39)$$





# Algoritmul Baum-Welch (V)

$$\bar{\pi}_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t = 1) = \gamma_1(i) \quad (39)$$

$$\begin{aligned} a_{i,j}^- &= \frac{\text{nr. estimat de tranziții din } S_i \text{ la } S_j}{\text{nr. estimat de tranziții din } S_i} \\ &= \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \end{aligned} \quad (40)$$



# Algoritmul Baum-Welch (V)

$$\bar{\pi}_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t = 1) = \gamma_1(i) \quad (39)$$

$$\begin{aligned} \bar{a}_{i,j} &= \frac{\text{nr. estimat de tranziții din } S_i \text{ la } S_j}{\text{nr. estimat de tranziții din } S_i} \\ &= \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \end{aligned} \quad (40)$$

$$\begin{aligned} \bar{b}_{j,k} &= \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} \\ &= \frac{\sum_{t=1, O_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \end{aligned} \quad (41)$$



# Algoritmul Baum-Welch (VI)

## Algoritmul 5 Algoritm Baum-Welch

```

1: intrări:  $O \leftarrow$  secvența de observații,  $\epsilon \leftarrow$  prag de convergență
2:
   {Initializare}
3: init. uniformă  $\Pi$  ( $\Pi_i = 1/N, 1 \leq i \leq N$ )
4: init. aleatoare  $a_{i,j}$ , a. î.  $\sum_{j=1}^N a_{i,j} = 1, \forall i = 1, \dots, N$ 
5: init. uniformă  $b_{j,k}$  ( $b_{j,k} = 1/M, 1 \leq j \leq N, 1 \leq k \leq M$ )
6: init  $\log(P(O|\bar{\lambda})) = 0$ 
7: repeat
8:    $\log(P(O|\lambda)) = \log(P(O|\bar{\lambda}))$ 
9:
   {E STEP - calculeaza variantele scalate pentru  $\alpha$  și  $\beta$  și probabilitatea curentă (log
   likelihood -  $\log(P(O|\bar{\lambda}))$ ) a secvenței observate}
10:   $[\log(P(O|\bar{\lambda})), \hat{\alpha}, \hat{\beta}, \text{Scale}] = \text{forward\_backward}(O, \Pi, A, B)$ 
11:
   {M STEP - recalculeaza  $\Pi$ ,  $A$  și  $B$ }
12:   $\Pi = \text{update\_pi\_procedure}(\hat{\alpha}, \hat{\beta}, \text{Scale})$ 
13:   $A = \text{update\_A\_procedure}(O, \hat{\alpha}, \hat{\beta}, \text{Scale})$ 
14:   $B = \text{update\_B\_procedure}(O, \hat{\alpha}, \hat{\beta}, \text{Scale})$ 
15: until  $\log(P(O|\bar{\lambda})) - \log(P(O|\lambda)) < \epsilon$ 

```



# Algoritmul Baum-Welch (VI)

---

## Algoritmul 6 Algoritm Baum-Welch

---

```

1: Function update_pi_procedure( $\hat{\alpha}$ ,  $\hat{\beta}$ , Scale)
2: for  $i = 1$  to  $N$  do
3:    $\Pi_i = \frac{\hat{\alpha}_1(i) \cdot \hat{\beta}_1(i) / \text{Scale}(1)}{\sum_{j=1}^N \hat{\alpha}_1(j) \cdot \hat{\beta}_1(j) / \text{Scale}(1)}$ 
4: end for
5: return  $\Pi$ 
6: EndFunction

7: Function update_A_procedure( $O$ ,  $\hat{\alpha}$ ,  $\hat{\beta}$ , Scale)
8: for  $i = 1$  to  $N$  do
9:   for  $j = 1$  to  $N$  do
10:     $a_{i,j} = \frac{\sum_{t=1}^{T-1} \hat{\alpha}_{t,i} \cdot a_{ij} \cdot b_j(o_{t+1}) \cdot \hat{\beta}_{t+1,j}}{\sum_{t=1}^{T-1} \sum_{j=1}^N \hat{\alpha}_{t,i} \cdot a_{i,j} \cdot b_j(o_{t+1}) \cdot \hat{\beta}_{t+1,j}}$ 
11:   end for
12: end for
13: return  $a$ 
14: EndFunction

```

---



# Algoritmul Baum-Welch (VI)

---

## Algoritmul 7 Algoritm Baum-Welch

---

```

1: Function update_B_procedure( $O, \hat{\alpha}, \hat{\beta}, Scale$ )
2: for  $j = 1$  to  $N$  do
3:   for  $k = 1$  to  $M$  do
4:     
$$b_{j,k} = \frac{\sum_{t=1}^T \mathbf{1}_{O(t)=v_k} \hat{\alpha}_t(j) \cdot \hat{\beta}_t(j) / Scale(t)}{\sum_{t=1}^T \hat{\alpha}_t(j) \cdot \hat{\beta}_t(j) / Scale(t)}$$

5:   end for
6: end for
7: return  $b$ 
8: EndFunction

```

---